News Agency Classification

Annotation Guidelines

April 2023

Lea Marxen

In the following, you will find some guidelines and comments on how to annotate the corpus for the *impresso* News Agency Classification.

1. News Agency Labels

The News Agency Labels can be found in the layer "*Impresso* News Agencies".

1.1 News Agencies

Only annotate News Agencies when they provide the information contained in the articles. News Agency mentions which occur because the content is *about* the News Agency but not *from* them should not be annotated, e.g. if the article treats a change of personnel within a News Agency or an acquisition of a News Agency by another (and this information does not come from the News Agency itself), see also Fig. 1.

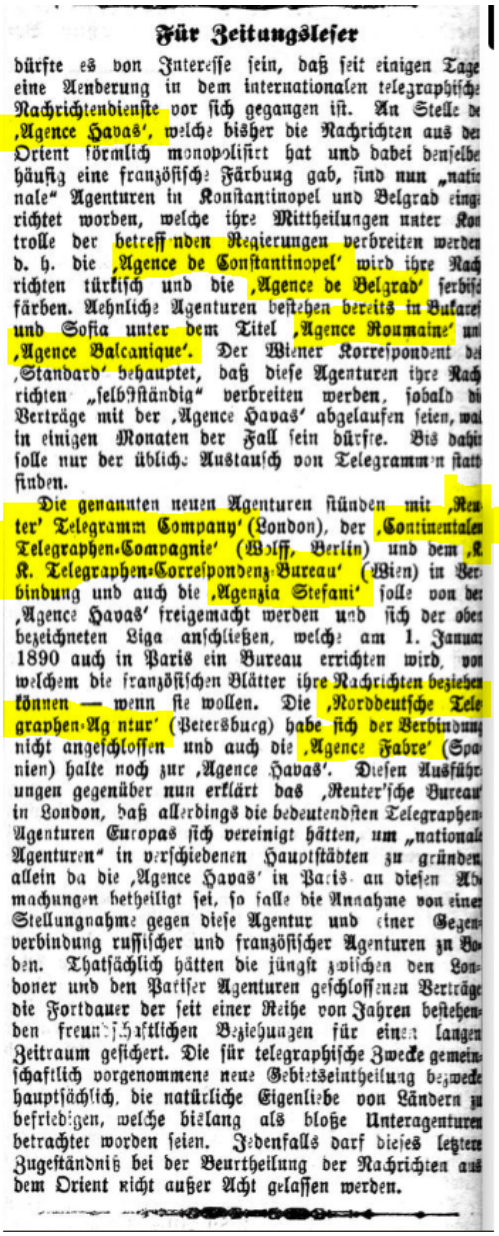

Für Zeitungsleser

dürfte es von Interesse sein, daß seit einigen Tage eine Aenderung in dem internationalen telegraphische Nachrichtendienste vor sich gegangen ist. An Stelle de ‚Agence Havas', welche bisher die Nachrichten aus der Orient förmlich monopolisirt hat und dabei denselbe häufig eine französische Färbung gab, sind nun „natio nale" Agenturen in Konstantinopel und Belgrad eing richtet worden, welche ihre Mittheilungen unter Kon trolle der betreffenden Regierungen verbreiten werden d. h. die ‚Agence de Constantinopel' wird ihre Nach richten türkisch und die ‚Agence de Belgrad' serbisch färben. Aehnliche Agenturen bestehen bereits in Bukarest und Sofia unter dem Titel ‚Agence Roumaine' und ‚Agence Balcanique'. Der Wiener Korrespondent des ‚Standard' behauptet, daß diese Agenturen ihre Nach richten „selbstständig" verbreiten werden, sobald die Verträge mit der ‚Agence Havas' abgelaufen seien, was in einigen Monaten der Fall sein dürfte. Bis dahin solle nur der übliche Austausch von Telegrammen statt finden.

Die genannten neuen Agenturen stünden mit ‚Reuter' Telegramm Company' (London), der ‚Continentalen Telegraphen-Compagnie' (Wolff, Berlin) und dem ‚K. K. Telegraphen-Correspondenz-Bureau' (Wien) in Verbindung und auch die ‚Agenzia Stefani' solle von der ‚Agence Havas' freigemacht werden und sich der oben bezeichneten Liga anschließen, welche am 1. Januar 1890 auch in Paris ein Bureau errichten wird, von welchem die französischen Blätter ihre Nachrichten beziehen können — wenn sie wollen. Die ‚Norddeutsche Tele graphen-Ag ntur' (Petersburg) habe sich der Verbindung nicht angeschlossen und auch die ‚Agence Fabre' (Spa nien) halte noch zur ‚Agence Havas'. Diesen Ausführ ungen gegenüber nun erklärt das ‚Reuter'sche Bureau in London, daß allerdings die bedeutendsten Telegraphen-Agenturen Europas sich vereinigt hätten, um „nationale Agenturen" in verschiedenen Hauptstädten zu gründen, allein da die ‚Agence Havas' in Paris an diesen Ab machungen betheiligt sei, so falle die Annahme von einer Stellungnahme gegen diese Agentur und einer Gegen verbindung russischer und französischer Agenturen zu Bo den. Thatsächlich hätten die jüngst zwischen den Lon doner und den Pariser Agenturen geschlossenen Verträge die Fortdauer der seit einer Reihe von Jahren bestehen den freundschaftlichen Beziehungen für einen langen Zeitraum gesichert. Die für telegraphische Zwecke gemein schaftlich vorgenommene neue Gebietseintheilung bezwecke hauptsächlich, die natürliche Eigenliebe von Ländern zu befriedigen, welche bislang als bloße Unteragenturen betrachtet worden seien. Jedenfalls darf dieses letztere Zugeständniß bei der Beurtheilung der Nachrichten aus dem Orient nicht außer Acht gelassen werden.

Fig. 1: Example for News Agency mentions which should not be annotated.

The following News Agency labels exist for annotation:

Abbr.	Other possible Reference In Newspapers	News Agency	Country	Creation	End
AFP	(AFP), (Afp.), (A. F. P.), Agence France Presse	Agence France-Presse	France	1944	
ANP		Algemeen Nederlands Persbureau	Netherlands	1934	
ANSA		Agenzia Nationale Stampa Associata	Italy	1945	
AP	(AP)	Associated Press	USA	1848	
APA		Austria Press Agentur	Austria	1946	
ATS / SDA	Agence télégraphique suisse	Agence Telegraphique Suisse / Schweizerische Depeschenagentur	Switzerland	1894	
BELGA	(Belga)	Agence télégraphique belge de Presse	Belgium	1920	
BTA	Agence Bulgare, BTA	Bulgarska Telegrafitscheka Agentzia / Agence Bulgare / Bulgarian Telegraph Agency	Bulgaria	1898	
CTK		Czechoslavenska Tiskova Kancelar / Agence Ceteka	Czechoslovakia/Czech	1918	
DDP / DAPD	Ddp, dapd	Deutscher Depeschendienst / Deutscher Auslands-Depeschendienst	Germany	1971	2013
DNB	(D. N. B.)	Deutsches Nachrichtenbüro GmbH	Germany	1933	1945
DOMEI	(Domei.)	Domei Tsushin/Domei News Agency	Japan	1936	1945
DPA	(DPA)	Deutsche Presse Agentur	Germany (GFR)	1949	
Europapress	(Europapreß.), (Europapr.)	Europapress	Germany		
Extel	Agence Extel, (Extel.)	Exchange Telegraph Co. Ltd.	United Kingdom	1872	1993
HAVAS	(Havas.), Havas	Havas	France	1835	
Interfax		Interfax News Agency	Russia	1989	
PAP		Polska Agencja Prasowa	Poland	1944	
REUTERS	(Reuter), (Reuter.), Reutermeldung, Reuter'schen Büreau, Reuter-Telegramm	Reuters	United Kingdom	1851	

SPK / SMP		Schweizerische Politische Korrespondenz / Schweizer Mittelpresse (until 1947)	Switzerland	1917	1993
Stefani	Agenzia Stefani, (Stefani.)	Agenzia Stefani	Italy	1853	1945
TANJUG		Telegrafska Agencija nova Jugoslavija	Yugoslavia/Serbia	1943	2018
TASS	ITAR-TASS, Taß, Telegraphen-Agentur der Sowietunion, Telegraphen-Agentur der U.S.S.R.	Telegrafnoie Agenstvo sovietskavo Soyusa	Russia	1925	
TT		Tidningarnas Telegrambyra	Sweden	1921	
Telunion	TU, (Telunion.)	Telegraphen-Union	Germany	1913	1934
UPI		United Press International	USA	1958	1990
Wolff	(Wolff.), Wolffbüro, Wolffsbüro, Kontinental-Telegraphencompagnie	Wolffs Telegraphisches Bureau	Germany	1849	1934

1.2 The *unk* label

The *unk* label should be used for News Agencies whose name is not contained in the predefined labels. If this is the case, and you are sure that you are tagging a news agency, report the annotation as successful when finishing it. If you are unsure whether you are tagging a news agency or an article author, please report it as a problem when finishing the annotation of the document and type “unk” in the message field:

Fig. 2: Press the indicated button to finish the annotation of a document.

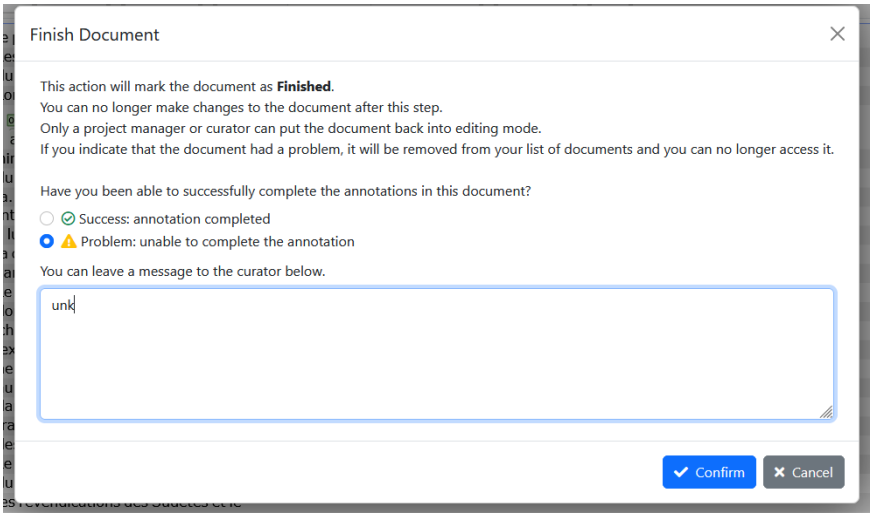

Fig. 3: Reporting a problem with message "unk" when finishing the document annotation

1.3 The *pers.ind.articleauthor* label

At some time, newspapers began crediting the authors of the articles. This can take the same form as crediting a News Agency, as can be seen in Figure 4. If you see this, use the *pers.ind.articleauthor* label to annotate the author of the article.

ÉTATS-UNIS

Grâce refusée à Troy Davis

La justice américaine a refusé mardi d'accorder sa grâce à Troy Davis, un Noir condamné à mort en 1991 pour le meurtre d'un policier blanc et devenu un symbole de la lutte contre la peine de mort. Cette décision tombe à la veille de son exécution prévue dans l'Etat de Géorgie. «*Le comité a refusé sa clémence*», a indiqué dans un communiqué le comité des grâces de Géorgie. La réunion de ce comité à Atlanta, la capitale de Géorgie, était considérée comme la dernière chance pour le condamné de voir sa peine de mort commuée en prison à vie, le gouverneur de l'Etat ne disposant pas du droit de grâce. L'exécution de Troy Davis par injection mortelle est programmée jeudi à 1h en Suisse à la prison de Jackson, malgré des doutes sur sa culpabilité. ATS-REUTERS

FRANCE

Vente de manuscrits de Gainsbourg

Les manuscrits des chansons «Sorry Angel», «Love on the beat», «No Comment», «Hmm Hmm Hmm» et de «You're under arrest» seront mis en vente par Sotheby's Paris le 9 novembre prochain. Des notes diverses, des tapuscrits ainsi que des photos inédites de Serge Gainsbourg (1928-1991) réalisées pour un magazine anglais compléteront cette vente. Le brouillon manuscrit de «Love on the beat» (1984) est peut-être le plus fascinant. Selon les organisateurs de la vente, ces deux pages comportent de très nombreuses variantes et corrections faisant apparaître en filigrane les influences baudelairiennes présentes dans toute l'œuvre de l'artiste (estimation: entre 12 000 et 18 000 euros). PHV

NIDWALD

Un soldat blessé lors d'un exercice

La justice militaire enquête depuis un mois sur un incendie qui a fait un blessé lors d'un exercice à Oberdorf (NW), près de Stans. Souffrant de blessures légères à moyennes, ce soldat en cours de répétition avait reçu l'ordre d'allumer un feu destiné à être éteint par des soldats au centre de formation de la Swisscoy. Les faits se sont produits le 23 août dernier, a indiqué hier la justice militaire. Le blessé n'était pas membre de la troupe qui devait être envoyée au Kosovo. Motocycliste, il faisait partie d'un détachement responsable de l'exploitation des installations du centre de formation Swissint. Les circonstances de l'accident font l'objet d'une enquête. L'investigation en est à son stade initial. Des spécialistes de l'institut médico-légal de la ville de Zurich se sont joints aux enquêteurs. ATS

Fig. 4: Articles with News Agency credentials (yellow) and author credentials (red)

If you are unsure whether a reference belongs to a News Agency or the article other, label the token with *unk* and follow the procedure from 1.2.

2. OCR noise

There exist two different options to deal with OCR noise, one on document level to discard the article and one on token level to correct the spelling of a News Agency mention.

2.1 Noisy article

If a document is too noisy to annotate, you can indicate this by setting the label *non_usable* to “Yes” in the Document Metadata. For this, go to “Document Metadata” in the menu bar on the left, as indicated in Figure 5.

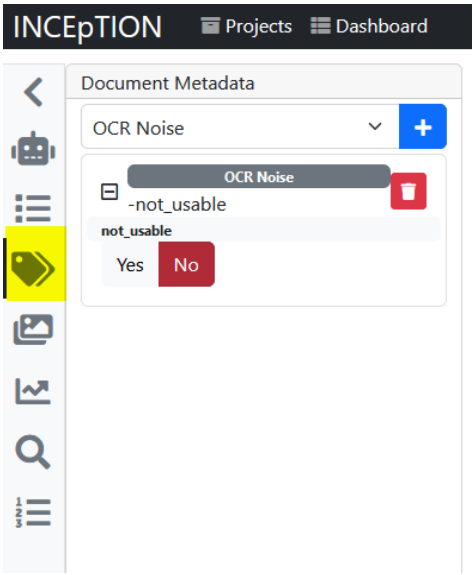

Fig. 5: Location of Document Metadata

2.2 Noisy News Agency Mention

If the OCR transcription of a News Agency mention is incorrect, please correct the transcription (and set the *noisy_ocr* tag to “Yes”).

Concerning the token boundaries, we will follow the specifications from the “Named Entity Annotation Guidelines” (HIPE):

Special cases with noisy OCR:
When it is difficult to establish the boundary of a mention because of noisy OCR:

- *look at the image*
- *include, in the annotation, the garbage characters which you think should have been recognized and should be part of the mention*

- *mark the mention with the flag “noisy-entity” and add your OCR hypothesis correction.*

*ex: in the string Trève * (which stands for Trèves), the full string Trève * should be annotated, not only Trève.*

3. Token boundaries

This section clarifies which part of a News Agency mention should be marked for annotation.

3.1 Abbreviations

Specification when to include "." in annotation:

- **Include**: abbreviation of a name (e.g. "ag.", "Ag. Télégr. Suisse", "D.N.B.")
- **Do not include:** at the end of an agency name (e.g. Havas. → Havas) or the acronym without points in between (e.g. AFP. → AFP)

3.2 Compounds / Proper Names

Do not include the words "agence" or "Agentur" in the annotation (e.g. agence [**Extel**]), except if they belong to a proper name (e.g. Agence France Presse, Agence Télégraphique Suisse).

Regarding German compounds, only include the name of the agency, e.g. [**Reuter**]meldung, [**Reuter**]-Telegramm.
Also note the following instructions from the "Named Entity Annotation Guidelines" (HIPE):

Special case with German compounds: Apply the cross-lingual or decomposition test, i.e. translate the compound to French and in the German compound annotate only what should be annotated in French.

> *The connecting "s" in German compounds is not annotated:*
> *Völkerbundsmitgliedern*
> *=> only Völkerbund is annotated*
> *< org .adm> Völkerbund </ org .adm> smitgliedern*

4. Remaining Annotation Issues

If it remains unclear how to annotate a certain mention, note the issue in the following file:

Google Document for Annotation issues

Resolving issues jointly and thus creating further examples of “best practice" can also ensure that the annotations will be as consistent as possible.